

# Lab02\_Barboza

Guilherme H D S Barboza Gonçalves 266060

## Pacotes

```
library(readr)
library(dplyr)
```

Attaching package: 'dplyr'

The following objects are masked from 'package:stats':

`filter`, `lag`

The following objects are masked from 'package:base':

`intersect`, `setdiff`, `setequal`, `union`

```
library(ggcal)
library(ggplot2)
```

## 1. Quais são as estatísticas suficientes para a determinação do percentual de voos atrasados na chegada (`ARRIVAL_DELAY > 10`)?

Para cada grupo (dia, mês, Cia. Aérea), basta guardar `n` (total de voos) e `n_delay` (voos com `ARRIVAL_DELAY > 10`). O percentual final é `n_delay / n`. Como são somas simples, dá pra calcular em cada lote separadamente e depois somar entre os lotes sem perder informação.

## 2. Crie uma função chamada getStats

Filtra as Cias. AA, DL, UA e US, remove valores faltantes, agrupa por dia/mês/Cia. Aérea e retorna as estatísticas suficientes como um tibble, recebendo os argumentos `input` e `pos`.

```
getStats <- function(input, pos) {  
  input %>%  
    filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%  
    filter(!is.na(ARRIVAL_DELAY)) %>%  
    group_by(YEAR, MONTH, DAY, AIRLINE) %>%  
    summarise(  
      n          = n(),  
      n_delay    = sum(ARRIVAL_DELAY > 10),  
      .groups    = "drop"  
    )  
}
```

## 3. Leitura em lotes com read\_csv\_chunked

Importa `flights.csv.zip` em lotes de 100 mil registros, com callback aplicando `getStats`, e `col_types` lendo apenas as colunas de interesse.

```
col_types <- cols_only(  
  YEAR          = col_integer(),  
  MONTH         = col_integer(),  
  DAY           = col_integer(),  
  AIRLINE       = col_character(),  
  ARRIVAL_DELAY = col_double()  
)  
  
stats_por_lote <- read_csv_chunked(  
  file          = "flights.csv",  
  callback      = DataFrameCallback$new(getStats),  
  chunk_size    = 100000,  
  col_types     = col_types  
)  
  
stats_por_lote
```

# A tibble: 1,478 x 6

|    | YEAR  | MONTH | DAY   | AIRLINE | n     | n_delay |
|----|-------|-------|-------|---------|-------|---------|
|    | <int> | <int> | <int> | <chr>   | <int> | <int>   |
| 1  | 2015  | 1     | 1     | AA      | 1379  | 514     |
| 2  | 2015  | 1     | 1     | DL      | 1558  | 132     |
| 3  | 2015  | 1     | 1     | UA      | 1269  | 367     |
| 4  | 2015  | 1     | 1     | US      | 1028  | 201     |
| 5  | 2015  | 1     | 2     | AA      | 1508  | 649     |
| 6  | 2015  | 1     | 2     | DL      | 2261  | 406     |
| 7  | 2015  | 1     | 2     | UA      | 1411  | 493     |
| 8  | 2015  | 1     | 2     | US      | 1174  | 229     |
| 9  | 2015  | 1     | 3     | AA      | 1425  | 767     |
| 10 | 2015  | 1     | 3     | DL      | 2021  | 702     |

# i 1,468 more rows

## 4. Crie uma função chamada computeStats

Combina as estatísticas suficientes de todos os lotes e retorna um tibble com as colunas Cia, Data (formato AAAA-MM-DD) e Perc (percentual entre 0 e 1).

```
computeStats <- function(x) {
  x %>%
    group_by(AIRLINE, YEAR, MONTH, DAY) %>%
    summarise(
      n = sum(n),
      n_delay = sum(n_delay),
      .groups = "drop"
    ) %>%
    mutate(
      Data = as.Date(paste(YEAR, MONTH, DAY, sep = "-")),
      Perc = n_delay / n
    ) %>%
    select(Cia = AIRLINE, Data, Perc)
}

resultado <- computeStats(stats_por_lote)
resultado
```

```
# A tibble: 1,276 x 3
  Cia   Data      Perc
  <chr> <date>    <dbl>
1 AA    2015-01-01 0.373
```

```

2 AA      2015-01-02 0.430
3 AA      2015-01-03 0.538
4 AA      2015-01-04 0.602
5 AA      2015-01-05 0.491
6 AA      2015-01-06 0.366
7 AA      2015-01-07 0.355
8 AA      2015-01-08 0.307
9 AA      2015-01-09 0.342
10 AA     2015-01-10 0.280
# i 1,266 more rows

```

## 5. Produza um mapa de calor em formato de calendário para cada Cia. Aérea

Define a paleta de cores com `scale_fill_gradient`, do `#4575b4` ao `#d73027`, armazenada em `pal`; cria a função `baseCalendario(stats, cia)`; aplica para AA, DL, UA e US, guardando em `cAA`, `cDL`, `cUA` e `cUS`; e apresenta cada mapa de calor com título via `ggtitle`.

```

pal <- scale_fill_gradient(low = "#4575b4", high = "#d73027")

baseCalendario <- function(stats, cia) {
  sub <- stats %>% filter(Cia == cia)
  ggcal(sub$Data, sub$Perc)
}

cAA <- baseCalendario(resultado, "AA")
cDL <- baseCalendario(resultado, "DL")
cUA <- baseCalendario(resultado, "UA")
cUS <- baseCalendario(resultado, "US")


```

```

cAA + pal + ggtitle("Percentual de atrasos - American Airlines (AA)")


```

## Percentual de atrasos – American Airlines (AA)




```
cDL + pal + ggtitle("Percentual de atrasos - Delta Air Lines (DL)")
```

## Percentual de atrasos – Delta Air Lines (DL)




```
cUA + pal + ggtitle("Percentual de atrasos - United Airlines (UA)")
```

## Percentual de atrasos – United Airlines (UA)



```
cUS + pal + ggtitle("Percentual de atrasos - US Airways (US)")
```

## Percentual de atrasos – US Airways (US)



```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

[1] "2026-08-24 23:38:45 -03"